



Desarrollo de un sistema de inteligencia artificial para la detección de apendicitis sobre ecografía de abdomen.

Rafael Reyes Velasquez

Resumen

Este proyecto de investigación se enfoca en abordar la detección oportuna de apendicitis, una urgencia médica común, a través de la aplicación de inteligencia artificial a la interpretación de imágenes de ecografías de abdomen. La iniciativa busca proporcionar al personal médico una herramienta precisa y eficiente que permita acelerar el proceso de diagnóstico, reducir errores humanos y, en última instancia, mejorar la calidad de la atención médica. La propuesta se basa en la revisión de la literatura existente, la recopilación y preparación de datos basados en imágenes, el desarrollo de un modelo de inteligencia artificial y su integración en un sistema de apoyo a la decisión clínica. El alcance del proyecto se limita a la detección de apendicitis y su interpretación en ecografías de abdomen, con un enfoque claro en la validación clínica y la mejora continua del sistema. El impacto potencial de esta innovación en el ámbito de la atención médica es significativo, ya que puede acelerar el proceso de diagnóstico y mejorar la precisión, lo que beneficia tanto a los profesionales de la salud encargados de la atención a pacientes, como a los mismos pacientes, previniendo sea el caso complicaciones de esta patología que puede ocasionar la muerte u otros agravamientos médicos.

Objetivo general

Desarrollar un sistema basado en inteligencia artificial que sirva como herramienta de apoyo para el personal médico en la detección precisa de apendicitis mediante el análisis de imágenes de ecografías de abdomen.

Objetivos específicos

- Desarrollar algoritmos de inteligencia artificial que mejoren la precisión en la detección de casos de apendicitis en ecografías pediátricas.
- Establecer métricas específicas, como la sensibilidad y especificidad, para evaluar y ajustar continuamente el rendimiento del sistema en términos de precisión diagnóstica.
- Realizar sesiones de capacitación con el personal médico para asegurar una adopción efectiva del sistema, promoviendo su utilización como una herramienta de apoyo integral en el proceso de diagnóstico de apendicitis.
- Implementar estrategias de optimización de procesos para reducir significativamente el tiempo necesario para realizar el diagnóstico de apendicitis utilizando el sistema de inteligencia artificial.

Origen de los datos

Se hará uso de una base de datos pública proporcionada por el Hospital St. Hedwig en Regensburg, Alemania. Esta base de datos fue creada a partir de un estudio que recopiló y organizó información sobre una cohorte de pacientes pediátricos que presentaban dolor abdominal entre 2016 a 2021.

Es importante aclarar que la información fue validada por el personal del hospital alemán anteriormente mencionado; asimismo, el estudio que publica los datos fue aprobado por el comité de ética de la Universidad de Regensburg, se llevó a cabo según las regulaciones y pautas de dicha universidad y fue finalmente publicado a través del repositorio de datos de acceso abierto respaldado por el CERN, Zenodo, bajo la licencia de Creative Commons para usos no comerciales.

En este dataset se encuentran varios archivos en diferentes formatos que según sus creadores, Marcinkevičs et al. (2023), corresponden a imágenes de ecografía abdominal en modo B que “muestran diversas regiones de interés, como el cuadrante inferior derecho del abdomen, el apéndice, los intestinos, los ganglios linfáticos y los órganos reproductores”, además de conjuntos de datos que “incluyen información sobre pruebas de laboratorio, resultados de la exploración física, puntuaciones clínicas, como las puntuaciones de Alvarado y de apendicitis pediátrica, y resultados ecográficos elaborados por expertos”.

Nuevamente, citando directamente a Marcinkevičs et al. (2023), el dataset posee la siguiente estructura:

“US_Pictures/: carpeta con las imágenes originales de ecografía en modo B en formato BMP; las imágenes se denominan como <subject #>.<view #> *.bmp”. Se poseen 2092 sonogramas de 780 pacientes.

“app_data.xlsx: Archivo MS Excel con datos tabulares (la pestaña ‘Resumen de datos’ contiene una explicación de las variables); los números de asunto correspondientes de la carpeta US_Pictures/ se encuentran en la columna US_Number”

“multiple_in_one_: una lista de nombres de imágenes de ultrasonido que contienen varias instantáneas”

“test_set_codes_csv: una lista de puntos de datos del conjunto de prueba”

Según lo anterior, se estima que los datos son confiables, además de ser la única base de datos pública de este tipo que se pudo encontrar; sin embargo, esto no descarta una exploración más exhaustiva sobre el dataset para encontrar posibles fallas o falencias.

Datos Estructurados

Estos corresponden al archivo app_data.xlsx, en el repositorio de GitHub.

<https://github.com/mamut1485/ProyectoS.git>

Importar librerías de python

```
import matplotlib.pyplot as plt
import seaborn as sns
import pandas as pd
import numpy as np
```

```
# Ruta del archivo
file_path = 'https://raw.githubusercontent.com/mamut1485/ProyectoS/main/structured_data/app_data.xlsx'

# Cargar la primera hoja del archivo Excel en un DataFrame
df = pd.read_excel(file_path, sheet_name=0)
```

```
# Mostrar las primeras filas del DataFrame
df.head()
```

```
##      Age  BMI    Sex  ... Meteorism  Enteritis  Gynecological_Findings
## 0  12.68  16.9  female  ...      NaN      NaN                      NaN
## 1  14.10  31.9   male  ...      yes      NaN                      NaN
## 2  14.14  23.3  female  ...      yes      yes                      NaN
## 3  16.37  20.6  female  ...      NaN      yes                      NaN
## 4  11.08  16.9  female  ...      NaN      yes                      NaN
##
## [5 rows x 58 columns]
```

```
# Visualizamos las variables contenidas en el conjunto de datos
df.info()
```

```
## <class 'pandas.core.frame.DataFrame'>
## RangeIndex: 782 entries, 0 to 781
## Data columns (total 58 columns):
##  #   Column                                     Non-Null Count  Dtype
## ---  ---
##  0   Age                                     781 non-null    float64
##  1   BMI                                     755 non-null    float64
##  2   Sex                                     780 non-null    object
##  3   Height                                 756 non-null    float64
##  4   Weight                                779 non-null    float64
##  5   Length_of_Stay                        778 non-null    float64
##  6   Management                            781 non-null    object
##  7   Severity                              781 non-null    object
##  8   Diagnosis_Presumptive                 780 non-null    object
##  9   Diagnosis                             780 non-null    object
## 10  Alvarado_Score                        730 non-null    float64
## 11  Paedriatic_Appendicitis_Score        730 non-null    float64
## 12  Appendix_on_US                        777 non-null    object
## 13  Appendix_Diameter                     498 non-null    float64
## 14  Migratory_Pain                        773 non-null    object
## 15  Lower_Right_Abd_Pain                  774 non-null    object
## 16  Contralateral_Rebound_Tenderness      767 non-null    object
## 17  Coughing_Pain                         766 non-null    object
## 18  Nausea                                774 non-null    object
## 19  Loss_of_Appetite                      772 non-null    object
## 20  Body_Temperature                      775 non-null    float64
## 21  WBC_Count                             776 non-null    float64
## 22  Neutrophil_Percentage                 679 non-null    float64
## 23  Segmented_Neutrophils                 54 non-null     float64
## 24  Neutrophilia                         732 non-null    object
## 25  RBC_Count                             764 non-null    float64
## 26  Hemoglobin                            764 non-null    float64
## 27  RDW                                    756 non-null    float64
## 28  Thrombocyte_Count                    764 non-null    float64
## 29  Ketones_in_Urine                     582 non-null    object
## 30  RBC_in_Urine                         576 non-null    object
## 31  WBC_in_Urine                         583 non-null    object
## 32  CRP                                    771 non-null    float64
```

```
## 33 Dysuria 753 non-null object
## 34 Stool 765 non-null object
## 35 Peritonitis 773 non-null object
## 36 Psoas_Sign 745 non-null object
## 37 Ipsilateral_Rebound_Tenderness 619 non-null object
## 38 US_Performed 778 non-null object
## 39 US_Number 760 non-null float64
## 40 Free_Fluids 719 non-null object
## 41 Appendix_Wall_Layers 218 non-null object
## 42 Target_Sign 138 non-null object
## 43 Appendicolith 69 non-null object
## 44 Perfusion 63 non-null object
## 45 Perforation 81 non-null object
## 46 Surrounding_Tissue_Reaction 252 non-null object
## 47 Appendicular_Abscess 85 non-null object
## 48 Abscess_Location 13 non-null object
## 49 Pathological_Lymph_Nodes 203 non-null object
## 50 Lymph_Nodes_Location 121 non-null object
## 51 Bowel_Wall_Thickening 99 non-null object
## 52 Conglomerate_of_Bowel_Loops 43 non-null object
## 53 Ileus 60 non-null object
## 54 Coprostasis 71 non-null object
## 55 Meteorism 140 non-null object
## 56 Enteritis 66 non-null object
## 57 Gynecological_Findings 26 non-null object
## dtypes: float64(18), object(40)
## memory usage: 354.5+ KB
```

Exploración de datos perdidos

```
"""
Se identifican los valores vacíos para cada variable en las instancias.
Cantidad de Datos perdidos por variables, uasamos la funcion head para visualizar
los primeros 5 valores y ahorar espacio:
"""
```

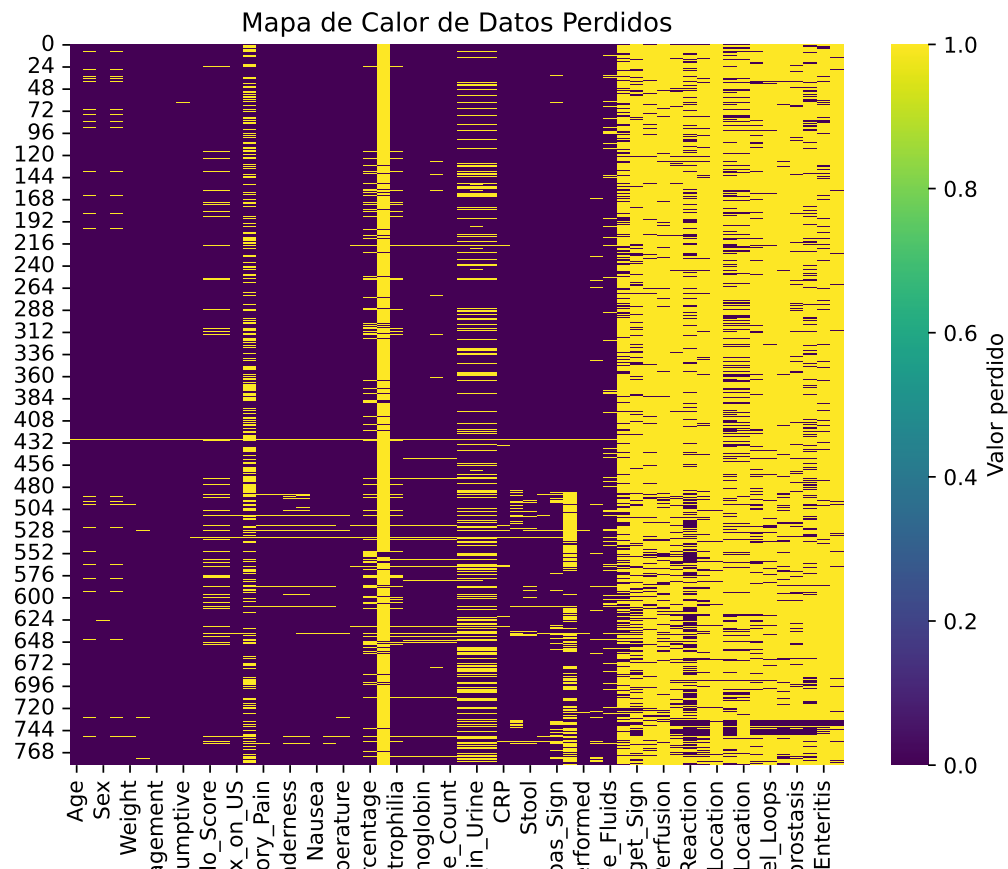
```
df.isnull().sum().head()
```

```
## Age 1
## BMI 27
## Sex 2
## Height 26
## Weight 3
## dtype: int64
```

Mapa de Calor de datos perdidos

```
"""
Utilizamos un mapa de calor para visualizar los datos perdidos de las variables
contenidas en el conjunto de datos.
"""
```

```
# Mapa de calor para visualizar datos perdidos
plt.figure(figsize=(8, 6))
sns.heatmap(df.isnull(), cmap='viridis', cbar=True,
cbar_kws={'label': 'Valor perdido'})
plt.title('Mapa de Calor de Datos Perdidos')
plt.show()
```



Variables Categóricas

```
# Identificación de las variables categóricas
categoricas = df.select_dtypes(include = ["object"]).columns.tolist()
df[categoricas]
```

##	Sex	Management	... Enteritis	Gynecological_Findings
## 0	female	conservative	...	NaN
## 1	male	conservative	...	NaN
## 2	female	conservative	...	yes
## 3	female	conservative	...	yes
## 4	female	conservative	...	yes
##

```
## 777 female primary surgical ... NaN NaN
## 778 female secondary surgical ... NaN NaN
## 779 female primary surgical ... NaN unauffällig
## 780 male primary surgical ... NaN NaN
## 781 male primary surgical ... NaN NaN
##
## [782 rows x 40 columns]
```

Variables Numéricas

```
# Identificación de las variables numéricas
numericas = df.select_dtypes(include = ['float64', 'int64']).columns.tolist()
df[numericas]
```

```
##      Age      BMI  Height  ...  Thrombocyte_Count  CRP  US_Number
## 0  12.680000  16.900000  148.0  ...      254.0    0.0    882.0
## 1  14.100000  31.900000  147.0  ...      151.0    3.0    883.0
## 2  14.140000  23.300000  163.0  ...      300.0    3.0    884.0
## 3  16.370000  20.600000  165.0  ...      258.0    0.0    886.0
## 4  11.080000  16.900000  163.0  ...      311.0    0.0    887.0
## ..      ...      ...      ...  ...      ...      ...      ...
## 777 12.413415  25.250476  166.5  ...      243.0   71.0    126.0
## 778 17.092402  20.429418  158.0  ...      310.0  245.0     NaN
## 779 14.992471  19.909972  152.0  ...      328.0    2.0    127.0
## 780  7.195072  14.295549  129.3  ...      345.0    8.0    128.0
## 781 11.509925  18.171441  146.5  ...      291.0    1.0    129.0
##
## [782 rows x 18 columns]
```

Normalizacion de datos perdidos

```
# Usando la funcion fillna(0), realizamos una normalizacion de los datos perdidos.

df['Age'] = df ['Age'].fillna(0)
df['BMI'] = df ['BMI'].fillna(0)
df['Sex'] = df ['Sex'].fillna(0)
df['Height'] = df ['Height'].fillna(0)
df['Weight'] = df ['Weight'].fillna(0)
df['Length_of_Stay'] = df ['Length_of_Stay'].fillna(0)
df['Management'] = df ['Management'].fillna(0)
df['Severity'] = df ['Severity'].fillna(0)
df['Diagnosis_Presumptive'] = df ['Diagnosis_Presumptive'].fillna(0)
df['Diagnosis'] = df ['Diagnosis'].fillna(0)
df['Alvarado_Score'] = df ['Alvarado_Score'].fillna(0)
df['Paedriatic_Appendicitis_Score'] = df ['Paedriatic_Appendicitis_Score'].fillna(0)
df['Appendix_on_US'] = df ['Appendix_on_US'].fillna(0)
df['Appendix_Diameter'] = df ['Appendix_Diameter'].fillna(0)
df['Migratory_Pain'] = df ['Migratory_Pain'].fillna(0)
df['Lower_Right_Abd_Pain'] = df ['Lower_Right_Abd_Pain'].fillna(0)
df['Contralateral_Rebound_Tenderness'] = df ['Contralateral_Rebound_Tenderness'].fillna(0)
```

```

df['Coughing_Pain']= df ['Coughing_Pain'].fillna(0)
df['Nausea']= df ['Nausea'].fillna(0)
df['Loss_of_Appetite']= df ['Loss_of_Appetite'].fillna(0)
df['Body_Temperature']= df ['Body_Temperature'].fillna(0)
df['WBC_Count']= df ['WBC_Count'].fillna(0)
df['Neutrophil_Percentage']= df ['Neutrophil_Percentage'].fillna(0)
df['Segmented_Neutrophils']= df ['Segmented_Neutrophils'].fillna(0)
df['Neutrophilia']= df ['Neutrophilia'].fillna(0)
df['RBC_Count']= df ['RBC_Count'].fillna(0)
df['Hemoglobin']= df ['Hemoglobin'].fillna(0)
df['RDW']= df ['RDW'].fillna(0)
df['Thrombocyte_Count']= df ['Thrombocyte_Count'].fillna(0)
df['Ketones_in_Urine']= df ['Ketones_in_Urine'].fillna(0)
df['RBC_in_Urine']= df ['RBC_in_Urine'].fillna(0)
df['WBC_in_Urine']= df ['WBC_in_Urine'].fillna(0)
df['CRP']= df ['CRP'].fillna(0)
df['Dysuria']= df ['Dysuria'].fillna(0)
df['Stool']= df ['Stool'].fillna(0)
df['Peritonitis']= df ['Peritonitis'].fillna(0)
df['Psoas_Sign']= df ['Psoas_Sign'].fillna(0)
df['Ipsilateral_Rebound_Tenderness']= df ['Ipsilateral_Rebound_Tenderness'].fillna(0)
df['US_Performed']= df ['US_Performed'].fillna(0)
df['US_Number']= df ['US_Number'].fillna(0)
df['Free_Fluids']= df ['Free_Fluids'].fillna(0)
df['Appendix_Wall_Layers']= df ['Appendix_Wall_Layers'].fillna(0)
df['Target_Sign']= df ['Target_Sign'].fillna(0)
df['Appendicolith']= df ['Appendicolith'].fillna(0)
df['Perfusion']= df ['Perfusion'].fillna(0)
df['Perforation']= df ['Perforation'].fillna(0)
df['Surrounding_Tissue_Reaction']= df ['Surrounding_Tissue_Reaction'].fillna(0)
df['Appendicular_Abscess']= df ['Appendicular_Abscess'].fillna(0)
df['Abscess_Location']= df ['Abscess_Location'].fillna(0)
df['Pathological_Lymph_Nodes']= df ['Pathological_Lymph_Nodes'].fillna(0)
df['Lymph_Nodes_Location']= df ['Lymph_Nodes_Location'].fillna(0)
df['Bowel_Wall_Thickening']= df ['Bowel_Wall_Thickening'].fillna(0)
df['Conglomerate_of_Bowel_Loops']= df ['Conglomerate_of_Bowel_Loops'].fillna(0)
df['Ileus']= df ['Ileus'].fillna(0)
df['Coprostasis']= df ['Coprostasis'].fillna(0)
df['Meteorism']= df ['Meteorism'].fillna(0)
df['Enteritis']= df ['Enteritis'].fillna(0)
df['Gynecological_Findings']= df ['Gynecological_Findings'].fillna(0)

df

```

##	Age	BMI	Sex	...	Meteorism	Enteritis	Gynecological_Findings
## 0	12.680000	16.900000	female	...	0	0	0
## 1	14.100000	31.900000	male	...	yes	0	0
## 2	14.140000	23.300000	female	...	yes	yes	0
## 3	16.370000	20.600000	female	...	0	yes	0
## 4	11.080000	16.900000	female	...	0	yes	0
##
## 777	12.413415	25.250476	female	...	0	0	0
## 778	17.092402	20.429418	female	...	0	0	0

```
## 779  14.992471  19.909972  female  ...      0      0      unauffällig
## 780   7.195072  14.295549   male  ...      0      0              0
## 781  11.509925  18.171441   male  ...      0      0              0
##
## [782 rows x 58 columns]
```

```
#Rastreamos nuevamente los datos perdidos, No existen datos perdidos.
df.isnull().sum().head()
```

```
## Age      0
## BMI      0
## Sex      0
## Height   0
## Weight   0
## dtype: int64
```

Conversion a enteros bulianos las variables categoricas

```
"""
Dentro del conjunto de datos se encuentran variables de tipo categoricas, que
cuenta con datos yes, no y 0, se procede a convertirlas en numericas remplazando
los valores por 0 y 1 , respectivamente.
"""
```

```
df['Migratory_Pain'] = df['Migratory_Pain'].replace("yes", '1').replace("no", '0')
df['Lower_Right_Abd_Pain'] = df ['Lower_Right_Abd_Pain'].replace("yes", '1').replace("no", '0')
df['Contralateral_Rebound_Tenderness'] = df ['Contralateral_Rebound_Tenderness'].replace("yes", '1').repl
df['Coughing_Pain'] = df ['Coughing_Pain'].replace("yes", '1').replace("no", '0')
df['Nausea'] = df ['Nausea'].replace("yes", '1').replace("no", '0')
df['Loss_of_Appetite'] = df ['Loss_of_Appetite'].replace("yes", '1').replace("no", '0')
df['Neutrophilia'] = df ['Neutrophilia'].replace("yes", '1').replace("no", '0')
df['Dysuria'] = df ['Dysuria'].replace("yes", '1').replace("no", '0')
df['Psoas_Sign'] = df ['Psoas_Sign'].replace("yes", '1').replace("no", '0')
df['Ipsilateral_Rebound_Tenderness'] = df ['Ipsilateral_Rebound_Tenderness'].replace("yes", '1').replace(
df['US_Performed'] = df ['US_Performed'].replace("yes", '1').replace("no", '0')
df['Free_Fluids'] = df ['Free_Fluids'].replace("yes", '1').replace("no", '0')
df['Target_Sign'] = df ['Target_Sign'].replace("yes", '1').replace("no", '0')
df['Surrounding_Tissue_Reaction'] = df ['Surrounding_Tissue_Reaction'].replace("yes", '1').replace("no", '
df['Bowel_Wall_Thickening'] = df ['Bowel_Wall_Thickening'].replace("yes", '1').replace("no", '0')
df['Conglomerate_of_Bowel_Loops'] = df ['Conglomerate_of_Bowel_Loops'].replace("yes", '1').replace("no", '
df['Ileus'] = df ['Ileus'].replace("yes", '1').replace("no", '0')
df['Coprostasis'] = df ['Coprostasis'].replace("yes", '1').replace("no", '0')
df['Meteorism'] = df ['Meteorism'].replace("yes", '1').replace("no", '0')
df['Enteritis'] = df ['Enteritis'].replace("yes", '1').replace("no", '0')
df['Pathological_Lymph_Nodes'] = df ['Pathological_Lymph_Nodes'].replace("yes", '1').replace("no", '0')

df
```

```
##          Age          BMI      Sex  ...  Meteorism  Enteritis  Gynecological_Findings
## 0    12.680000   16.900000  female  ...           0           0              0
## 1    14.100000   31.900000   male   ...           1           0              0
```



```
## 2    14.140000  23.300000  female ...      1      1      0
## 3    16.370000  20.600000  female ...      0      1      0
## 4    11.080000  16.900000  female ...      0      1      0
## ..      ...      ...      ...      ...      ...      ...
## 777   12.413415  25.250476  female ...      0      0      0
## 778   17.092402  20.429418  female ...      0      0      0
## 779   14.992471  19.909972  female ...      0      0      0
## 780    7.195072  14.295549   male ...      0      0      0
## 781   11.509925  18.171441   male ...      0      0      0
##
## [782 rows x 58 columns]
```

Depuracion de registros sin ID

```
"""
Se borran los datos con los cuales no se tiene una relacion con imagenes
diagnosticas tomadas, estos se reflejan en cero en la columna US_Number,
registros que no cuentan con imagenes relacionadas con el estudio.
"""
```

```
df = df[df['US_Number'] != 0]
```

```
"""
Procedemos a limpiar el conjunto de datos, para quedarlos con las variables
definitivas del conjunto de datos, creamos un nuevo dataset con el conjunto
de datos definitivo.
"""
```

```
df2 = df[['Age', 'BMI', 'Sex', 'Height', 'Weight', 'Length_of_Stay', 'Management',
          'Severity', 'Diagnosis_Presumptive', 'Diagnosis',
          'Appendix_on_US', 'Migratory_Pain', 'US_Number',]]
```

```
df2
```

```
##      Age      BMI      Sex ... Appendix_on_US Migratory_Pain US_Number
## 0    12.680000  16.900000  female ...      yes      0      882.0
## 1    14.100000  31.900000   male ...      no      1      883.0
## 2    14.140000  23.300000  female ...      no      0      884.0
## 3    16.370000  20.600000  female ...      no      1      886.0
## 4    11.080000  16.900000  female ...      yes     0      887.0
## ..      ...      ...      ...      ...      ...      ...
## 775    7.882272  18.698225   male ...      yes     0      244.0
## 777   12.413415  25.250476  female ...      yes     1      126.0
## 779   14.992471  19.909972  female ...      no     0      127.0
## 780    7.195072  14.295549   male ...      yes     1      128.0
## 781   11.509925  18.171441   male ...      yes     0      129.0
##
## [760 rows x 13 columns]
```

Visualizacion de Distribuciones

```
# Distribuciones
fig, axs = plt.subplots(2, 2, figsize=(10, 10))

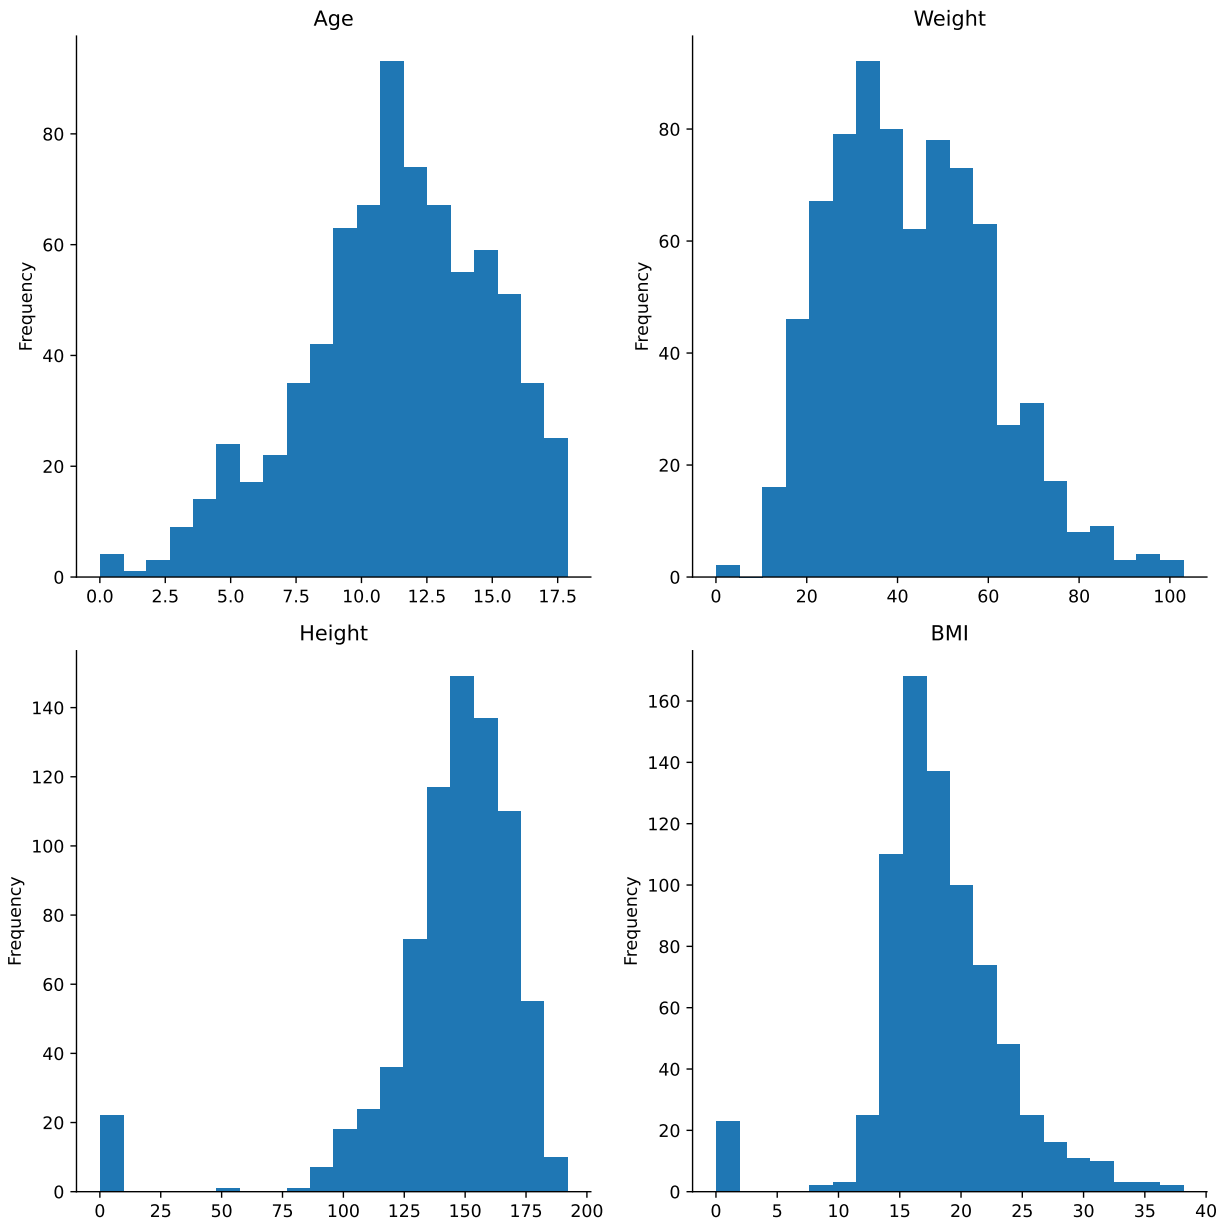
df2['Age'].plot(kind='hist', bins=20, ax=axs[0, 0], title='Age')
axs[0, 0].spines[['top', 'right']].set_visible(False)

df2['Weight'].plot(kind='hist', bins=20, ax=axs[0, 1], title='Weight')
axs[0, 1].spines[['top', 'right']].set_visible(False)

df2['Height'].plot(kind='hist', bins=20, ax=axs[1, 0], title='Height')
axs[1, 0].spines[['top', 'right']].set_visible(False)

df2['BMI'].plot(kind='hist', bins=20, ax=axs[1, 1], title='BMI')
axs[1, 1].spines[['top', 'right']].set_visible(False)

plt.tight_layout()
plt.show()
```



Visualizacion Variables Categorias

```
# Variables Categorias
fig, axs = plt.subplots(2, 2, figsize=(10, 10))

df2.groupby('Sex').size().plot(kind='barh', color=sns.color_palette('Dark2'), ax=axs[0, 0])
axs[0, 0].spines[['top', 'right']].set_visible(False)
axs[0, 0].set_title('Sex')

df2.groupby('Diagnosis').size().plot(kind='barh', color=sns.color_palette('Dark2'), ax=axs[0, 1])
axs[0, 1].spines[['top', 'right']].set_visible(False)
axs[0, 1].set_title('Diagnosis')
```


```

df2.groupby('Appendix_on_US').size().plot(kind='barh', color=sns.color_palette('Dark2'), ax=axes[1, 0])
axes[1, 0].spines[['top', 'right']].set_visible(False)
axes[1, 0].set_title('Appendix on US')

df2.groupby('Migratory_Pain').size().plot(kind='barh', color=sns.color_palette('Dark2'), ax=axes[1, 1])
axes[1, 1].spines[['top', 'right']].set_visible(False)
axes[1, 1].set_title('Migratory Pain')

plt.tight_layout()
plt.show()

```



Distribuciones en 2D

```
# Distribuciones en 2D
# número de subgráficos a 1x4
fig, axs = plt.subplots(1, 4, figsize=(20, 5))


# axs[0] para especificar la primera subgráfica
df2.plot(kind='scatter', x='Age', y='BMI', s=32, alpha=.8, ax=axs[0])
axs[0].spines[['top', 'right']].set_visible(False)

# axs[1] para la segunda subgráfica
df2.plot(kind='scatter', x='BMI', y='Height', s=32, alpha=.8, ax=axs[1])
axs[1].spines[['top', 'right']].set_visible(False)

# axs[2] para la tercera subgráfica
df2.plot(kind='scatter', x='Height', y='Weight', s=32, alpha=.8, ax=axs[2])
axs[2].spines[['top', 'right']].set_visible(False)


# axs[3] para la cuarta subgráfica
df2.plot(kind='scatter', x='Weight', y='Length_of_Stay', s=32, alpha=.8, ax=axs[3])
axs[3].spines[['top', 'right']].set_visible(False)

plt.tight_layout()
plt.show()
```




Distribuciones Facetadas


```
figsize = (12, 1.2 * len(df['Sex'].unique()))
plt.figure(figsize=figsize)
sns.violinplot(df2, x='Age', y='Sex', inner='stick', palette='Dark2')
sns.despine(top=True, right=True, bottom=True, left=True)
```



```
figsize = (12, 1.2 * len(df['Diagnosis'].unique()))
plt.figure(figsize=figsize)
sns.violinplot(df2, x='Age', y='Diagnosis', inner='stick', palette='Dark2')
sns.despine(top=True, right=True, bottom=True, left=True)
```



```
figsize = (12, 1.2 * len(df['Appendix_on_US'].unique()))
plt.figure(figsize=figsize)
sns.violinplot(df2, x='Age', y='Appendix_on_US', inner='stick', palette='Dark2')
sns.despine(top=True, right=True, bottom=True, left=True)
```



```
figsize = (12, 1.2 * len(df['Migratory_Pain'].unique()))
plt.figure(figsize=figsize)
sns.violinplot(df2, x='Age', y='Migratory_Pain', inner='stick', palette='Dark2')
sns.despine(top=True, right=True, bottom=True, left=True)
```

